

# Sistem Skrining Depresi Mahasiswa dengan Klasifikasi Risiko Multilevel

Early Detection System for Student Mental Health Risks

By: Arthur Pendragon

Dataset: [Student Depression Dataset](#)

Independent Data Science Project · 2026

# Problem Background

Depresi merupakan gangguan kesehatan mental serius yang menjadi kontributor utama **penurunan produktivitas dan kualitas hidup** di tingkat global, memengaruhi lebih dari **280 juta orang** di seluruh dunia (WHO). Pada sektor pendidikan, mahasiswa menjadi kelompok yang sangat rentan akibat akumulasi tekanan akademik, tuntutan finansial, dan dinamika sosial. Data di India bahkan menunjukkan bahwa **1 dari 20 individu** terindikasi depresi, menandakan adanya krisis kesehatan mental yang nyata pada populasi usia produktif.

Meskipun prevalensi kasus sangat tinggi, faktanya lebih dari **75% penderita** di negara berkembang tidak mendapatkan perawatan yang memadai. Di lingkungan kampus, kesenjangan ini diperparah oleh **keterbatasan rasio tenaga ahli** (psikolog/konselor) dibandingkan dengan jumlah mahasiswa yang harus dilayani. Hal ini memicu urgensi akan adanya sistem skrining awal yang objektif dan efisien.

Oleh karena itu, diperlukan pendekatan berbasis data melalui *Machine Learning* yang mampu melakukan **triage atau klasifikasi tingkat risiko**. Dengan sistem ini, keterbatasan sumber daya manusia di kampus dapat dioptimalkan melalui pemberian prioritas penanganan pada mahasiswa dengan risiko tertinggi, sehingga meminimalisir adanya kasus fatal yang tidak terdeteksi.

# Project Objectives

01

## Model Prediktif

Mengembangkan model machine learning untuk mendukung proses skrining awal depresi pada mahasiswa

03

## Identifikasi Faktor Kunci

Mengidentifikasi variabel prediktor paling signifikan yang mempengaruhi risiko depresi mahasiswa

02

## Klasifikasi Multilevel

Mengembangkan sistem klasifikasi risiko depresi dengan tiga tingkat: rendah, sedang, dan tinggi berdasarkan ambang batas probabilitas

04

## Intervensi Dini

Memberikan rekomendasi intervensi berdasarkan tingkat risiko untuk layanan konseling yang lebih efektif

# Dataset Overview

Dataset student depression dari Kaggle berisi berbagai variabel yang berkaitan dengan depresi mahasiswa, mencakup faktor demografis, akademik, psikologis, serta gejala depresi, yang dikumpulkan melalui survei di India.

## Struktur Dataset

- Dataset awal: **27.000+ responden**
- **17 variabel predictor**
- 1 variabel target (Depression: 1 (Ya) / 0 (Tidak))

## Sumber Data

Dataset diambil dari platform Kaggle dengan judul "Student Depression Dataset". Informasi lebih lanjut dapat ditemukan di:

[Kaggle - Student Depression Dataset](#)


❏ **Catatan:** Data dikumpulkan dari populasi mahasiswa di India. Karakteristik budaya, akademik, dan sosial mungkin berbeda dengan konteks Indonesia dan negara lainnya, sehingga **generalisasi hasil perlu dilakukan dengan hati-hati** dan membutuhkan validasi dengan data lokal.

# Data Understanding

Dataset mencakup berbagai aspek mahasiswa, mulai dari faktor akademik, gaya hidup, hingga Informasi personal yang berpotensi memengaruhi depresi.

| SAMPLE DATA : | Gender | Age  | Academic Pressure | CGPA | Degree  | Sleep Duration      | Dietary Habits | Depression |
|---------------|--------|------|-------------------|------|---------|---------------------|----------------|------------|
|               | Male   | 33.0 | 5.0               | 8.97 | B.Pharm | '5-6 hours'         | Healthy        | 1          |
|               | Female | 24.0 | 2.0               | 5.9  | BSc     | '5-6 hours'         | Moderate       | 0          |
|               | Male   | 31.0 | 3.0               | 7.03 | BA      | 'Less than 5 hours' | Healthy        | 0          |
|               | Female | 28.0 | 3.0               | 5.59 | BCA     | '7-8 hours'         | Moderate       | 1          |

| FEATURE GROUPS       |                                                                                      |                      |
|----------------------|--------------------------------------------------------------------------------------|----------------------|
| Groups               | Nama Fitur                                                                           | Tipe Data            |
| Personal             | Age, Gender, City, Suicidal Thoughts, Family History, Financial Stress               | Kategorikal, Numerik |
| Akademik & Pekerjaan | CGPA, Academic Pressure, Study Satisfaction, Degree, Work Pressure, Job Satisfaction | Kategorikal, Numerik |
| Gaya Hidup           | Sleep Duration, Dietary Habits, Work/Study Hours                                     | Kategorikal, Numerik |



# Data Issues & Solutions

## Masalah: Data Out-of-Domain

Beberapa data memiliki nilai yang tidak sesuai dengan domain dan tujuan dari pengembangan model

**Solusi:** Menghapus atau mengimputasi data berdasarkan jumlah keseluruhan data yang ditemukan

## Masalah: Data Error

Beberapa data yang memiliki nilai pengganti atau nilai tidak valid yang kemungkinan berasal dari ketentuan system atau human error

**Solusi:** Imputasi menggunakan median atau mean untuk variabel numerik dan modus untuk kategorikal.

## Masalah: Class Labeling

Target variabel biner digunakan untuk melatih model, kemudian hasil probabilitas prediksi dikonversi menjadi 3 kelas: Rendah, Sedang, dan Tinggi berdasarkan ambang batas probabilitas.

**Solusi:** Melakukan pembagian kelas berdasarkan ambang probabilitas prediksi

## Masalah: Outliers

Deteksi pencilan pada variabel numerik yang dapat mempengaruhi model

**Solusi:** Transformasi logaritmik dan capping menggunakan metode IQR (Interquartile Range) untuk mengurangi dampak pencilan

# Data Cleaning

## FILTERING & SELEKSI RESPONDEN

### 1 Filter Responden Non-Mahasiswa

Menghapus responden dengan nilai pada fitur Degree berupa **'Class 12'**, karena tidak sesuai dengan tujuan klasifikasi depresi mahasiswa perguruan tinggi.

### 2 Validasi Konsistensi Usia pada Jenjang Pendidikan

Terdapat responden dengan nilai Age yang tidak memungkinkan untuk menempuh jenjang pendidikan yang tercatat, sehingga data tersebut dihapus berdasarkan batas usia minimum per jenjang pendidikan.

### 3 Dominasi Nilai 'Student' pada Fitur Profession

Fitur Profession memiliki distribusi yang sangat tidak seimbang dengan hampir seluruh nilai merupakan 'Student', sehingga baris dengan profesi lain dihapus sebagai data out-of-domain.

## PENANGANAN KUALITAS DATA

### 4 Nilai Tidak Valid pada Fitur Kategorikal

Beberapa fitur kategorikal mengandung nilai tidak representatif seperti **'0'**, **'?'**, **'Others'**, dan lainnya yang tidak bermakna secara kontekstual, sehingga data tersebut perlu diimputasi menggunakan modus dari fitur yang bersangkutan.

### 5 Nilai Outliers pada Fitur Numerik

Beberapa fitur numerik mengandung nilai pencilan yang jumlahnya sangat sedikit di luar rentang umum, sehingga data tersebut ditangani menggunakan **domain-based clipping** dengan menetapkan batas berdasarkan distribusi data aktual pada masing-masing fitur.

# Feature Engineering

## 6 Feature Selection

Menghapus fitur yang tidak relevan atau redundan terhadap target klasifikasi.

| FITUR                                       | STATUS | ALASAN                                                                                         |
|---------------------------------------------|--------|------------------------------------------------------------------------------------------------|
| Id                                          | Hapus  | Identifier unik tanpa nilai prediktif.                                                         |
| Profession, Job Satisfaction, Work Pressure | Hapus  | Distribusi sangat homogen, tidak informatif bagi model.                                        |
| Have you ever had suicidal thoughts?        | Hapus  | Gejala depresi, bukan faktor — berpotensi data leakage dan tidak sesuai dengan tujuan project. |

## 7 Feature Transformation

### Degree Grouping

Nama gelar yang beragam dikelompokkan menjadi Education Level dengan 3 kategori → Bachelor, Master, dan Doctorate — agar representasi jenjang pendidikan lebih konsisten dan mudah diinterpretasikan oleh model.

### NILAI ASAL

|                           |   |           |
|---------------------------|---|-----------|
| B.Pharm, BSc, BA, BCA,... | → | Bachelor  |
| M.Tech, MSc, MBA,...      | → | Magister  |
| PhD, MD                   | → | Doctorate |



# Data Encoding

## 8 METODE ENCODING

### Label Encoding

Digunakan pada fitur **biner** yang hanya memiliki dua nilai — setiap nilai dipetakan ke 0 atau 1.

#### FEATURE

Gender

Family History  
Mental Illness

Have you ever had suicidal  
thoughts ?

#### CONTOH

Male → **0**

Female → **1**

### Ordinal Encoding

Digunakan pada fitur **bertingkat** yang memiliki urutan logis antar nilainya.

#### FEATURE

Dietary Habits

Sleep Duration

Financial Stress

#### CONTOH

Healthy → **2**

Moderate → **1**

Unhealthy → **0**

### Target Encoding

Digunakan khusus pada fitur **City** yang memiliki banyak kategori — setiap nilai diganti dengan rata-rata target variabel.

#### FEATURE

City

#### CONTOH

Mumbai → **0.57**

Bangalore → **0.63**

Kalyan → **0.68**

# Feature Scaling

## 9 NORMALIZATION

### Standard Scaler

Diterapkan pada seluruh fitur setelah proses encoding dan feature selection — mengubah setiap nilai menjadi distribusi dengan mean = 0 dan standar deviasi = 1.

$$z = (x - \mu) / \sigma$$

$\mu$  = mean fitur     $\sigma$  = standar deviasi     $x$  = nilai asli     $z$  = nilai terstandarisasi

### CONTOH HASIL SCALING

| FITUR | SEBELUM |   | SESUDAH |
|-------|---------|---|---------|
| Age   | 25      | → | -0.21   |
| Age   | 35      | → | 1.84    |
| CGPA  | 8.97    | → | 1.43    |
| CGPA  | 5.00    | → | -1.62   |

### HASIL AKHIR DATA PREPARATION

27.901

↓

21.751

Total baris data



17

↓

12


Total fitur

# Demographic overview




## Age & CGPA

Distribusi usia dan CGPA menunjukkan beberapa pola puncak, mengindikasikan adanya variasi karakteristik dalam populasi mahasiswa.



## Education Level






Mayoritas responden berada pada jenjang Bachelor, menunjukkan dominasi mahasiswa tingkat sarjana dalam dataset.



## Top 5 Cities

Distribusi responden tidak didominasi oleh satu kota tertentu, menunjukkan penyebaran geografis yang relatif luas.

# Behavioral Factors



## Tekanan pada Mahasiswa

Mayoritas mahasiswa berada pada tingkat tekanan akademik dan finansial menengah hingga tinggi, yang berpotensi meningkatkan risiko depresi.

## Gaya Hidup Mahasiswa


Pola tidur yang cenderung kurang optimal serta variasi kebiasaan makan menunjukkan adanya faktor gaya hidup yang berpotensi memengaruhi kesejahteraan mental mahasiswa.

## Kepuasan Studi

Kepuasan studi cenderung berada pada tingkat menengah, menunjukkan potensi ketidakpuasan pada sebagian mahasiswa.


# Numerical Features vs Target

● Depresi = Ya, ● Depresi = Tidak




Tingkat Financial Stress (1–5)

Semakin tinggi tingkat financial stress, semakin besar persentase mahasiswa yang mengalami depresi. Kategori level 4–5 menunjukkan dominasi signifikan pada kelompok depresi.



Usia Mahasiswa

Mahasiswa yang lebih muda menunjukkan kecenderungan memiliki probabilitas depresi sedikit lebih tinggi dibandingkan yang lebih tua, meskipun perbedaannya tidak terlalu signifikan.




Tingkat Academic Pressure (1–5)

Tingkat academic pressure yang lebih tinggi (level 4–5) didominasi oleh mahasiswa yang mengalami depresi, menunjukkan hubungan yang kuat antara tekanan akademik dan risiko depresi.


# Categorical Features vs Target

● Depresi = Ya, ● Depresi = Tidak




Dietary Habits

Mahasiswa dengan pola makan tidak sehat menunjukkan proporsi depresi yang jauh lebih tinggi, mengindikasikan hubungan yang kuat antara kebiasaan makan dan risiko kesehatan mental.



Family History of Mental Illness


Individu dengan riwayat keluarga gangguan mental menunjukkan tingkat depresi yang sedikit lebih tinggi, menandakan adanya hubungan yang bersifat moderat.



Gender

Tingkat depresi relatif serupa pada laki-laki dan perempuan, menunjukkan bahwa gender bukan merupakan faktor pembeda dalam dataset ini.

# Feature Correlation



## City & Depression Association

Cramér's V digunakan untuk mengukur hubungan antar variabel kategorikal.

| Fitur | Cramér's V | Interpretasi |
|-------|------------|--------------|
| City  | 0,07       | Weak         |

## KESIMPULAN

Hasil analisis **Exploratory Data Analyst (EDA)** menunjukkan bahwa depresi dipengaruhi oleh berbagai faktor dari aspek akademik, gaya hidup, hingga latar belakang keluarga. Oleh karena itu, **seluruh fitur diikutsertakan** dalam model untuk memastikan hasil prediksi memiliki **variansi informasi yang kaya** dan **tidak terpaku hanya pada faktor tekanan eksternal saja**

# Building the Prediction Model

## Algoritma yang Akan Dilakukan Perbandingan

### Model Linear

- Logistic Regression
- Linear SVM (SVC)
- SGD Classifier

### Ensemble Boosting

- XGBoost
- LightGBM
- CatBoost
- AdaBoost

### Berbasis Pohon

- Decision Tree
- Random Forest
- Extra Trees
- Gradient Boosting

### Probabilistik

- Gaussian Naive Bayes

### Instance & Kernel

- KNN
- Kernel SVM (RBF)
- MLP Neural Net
- QDA

## Klasifikasi Multilevel

Sistem klasifikasi berbasis ambang batas probabilitas:

- **Risiko Rendah:** Probabilitas  $< 30\%$
- **Risiko Sedang:**  $30\% \leq \text{Probabilitas} < 60\%$
- **Risiko Tinggi:** Probabilitas  $\geq 60\%$

## Evaluasi Model

Melihat perhitungan metrik kinerja yang dihasilkan untuk mengukur kinerja, akurasi, dan keandalan model *machine learning* pada data baru, memastikan model tidak *overfitting*, serta memilih algoritma terbaik untuk memecahkan masalah.



# Model Benchmarking

## TOP 3 MODEL

| Model               | Recall        | F1-Score      | ROC-AUC       | CV Accuracy   | Test Accuracy |
|---------------------|---------------|---------------|---------------|---------------|---------------|
| Kernel SVM (RBF)    | <b>0.8360</b> | <b>0.8227</b> | 0.8689        | 0.7859        | 0.8026        |
| CatBoost            | 0.8272        | 0.8203        | 0.8772        | 0.7881        | 0.8014        |
| Logistic Regression | 0.8268        | 0.8221        | <b>0.8780</b> | <b>0.7909</b> | <b>0.8040</b> |

## KESIMPULAN: LOGISTIC REGRESSION

### 1. ROC-AUC tertinggi (0.878)

Logistic Regression menghasilkan akurasi tertinggi di antara ketiga model pada data uji, menunjukkan kemampuan generalisasi terbaik terhadap data baru yang belum pernah dilihat model sebelumnya.

### 2. Performa paling stabil lintas validasi

Nilai CV Accuracy tertinggi menunjukkan model konsisten di berbagai partisi data, bukan hanya kebetulan bagus di satu split — indikator penting bahwa model akan tetap andal ketika diterapkan pada data baru.

### 3. Interpretabilitas yang relevan untuk konteks penelitian

Logistic Regression menghasilkan koefisien per fitur yang langsung bisa dijelaskan — peneliti dapat menunjukkan secara konkret faktor mana yang paling berpengaruh terhadap prediksi depresi. Ini adalah keunggulan yang tidak dimiliki Kernel SVM maupun CatBoost, dan sangat krusial jika hasil penelitian perlu dikomunikasikan kepada audiens non-teknis seperti psikolog atau pembuat kebijakan.

# Model Optimization

## METODE & KONFIGURASI

- Tuning menggunakan **Optuna** dengan Bayesian Optimization (TPE Sampler) sebanyak **100 trials**
- Evaluasi menggunakan **5-Fold Stratified Cross Validation**
- Model: **Logistic Regression**

## PARAMETER YANG DIOPTIMASI

| Parameter    | Rentang            |
|--------------|--------------------|
| C            | 0.001 – 100        |
| Penalty      | l1, l2, elasticnet |
| Max Iter     | 500 – 2000         |
| Class Weight | None, balanced     |

## OBJECTIVE FUNCTION

Composite score memaksimalkan deteksi depresi dengan memprioritaskan Recall

Score = 0.6 × Recall + 0.4 × F1

Recall 60%

F1-Score 40%

## PARAMETER TERBAIK – TRIAL #63

|                      |             |
|----------------------|-------------|
| Penalty              | Elastic Net |
| C                    | 0.00104     |
| l1_ratio             | 0.350       |
| Max Iter             | 2000        |
| Class Weight         | None        |
| Solver               | Saga        |
| Best Composite Score | 0.8317      |

# Model Evaluation

## SEBELUM VS SESUDAH OPTIMASI

| Metrik    | Sebelum | Sesudah | $\Delta$  |
|-----------|---------|---------|-----------|
| Recall    | 0.8268  | 0.8356  | +0.0088 ↑ |
| F1-Score  | 0.8221  | 0.8209  | -0.0012 → |
| Precision | 0.8175  | 0.8068  | -0.0107 ↓ |
| Accuracy  | 0.8040  | 0.8003  | -0.0037 ↓ |

## CONFUSION MATRIX TUNED MODEL

|        |               | Prediksi              |                       |
|--------|---------------|-----------------------|-----------------------|
| Aktual | Tidak Depresi | 1490<br>True Negative | 477<br>False Positive |
|        | Depresi       | 392<br>False Negative | 1992<br>True Positive |

## CLASSIFICATION REPORT

| Kelas         | Precision | Recall | F1-Score | Support |
|---------------|-----------|--------|----------|---------|
| Tidak Depresi | 0.79      | 0.76   | 0.77     | 1967    |
| Depresi       | 0.81      | 0.84   | 0.82     | 2384    |
| Weighted Avg  | 0.80      | 0.80   | 0.80     | 4351    |

## KESIMPULAN EVALUASI

Model **Logistic Regression (tuned)** dipilih sebagai model final karena menghasilkan **Recall tertinggi (0.8356)** dengan penurunan F1 yang tidak signifikan (−0.0012). Dalam konteks deteksi depresi, meminimalkan *false negative* lebih diprioritaskan dibandingkan mempertahankan Precision.

# Threshold Analysis

## MENGAPA DIPERLUKAN?

- Output biner hanya membedakan **depresi vs tidak** — tidak mencerminkan tingkat keparahan
- Probabilitas kontinu memungkinkan **intervensi bertingkat** sesuai urgensi klinis
- **Keterbatasan rasio tenaga ahli** (psikolog/konselor) dibandingkan mahasiswa yang perlu dilayani pada kampus

## KRITERIA PEMILIHAN THRESHOLD

0.3365

Recall  $\geq 0.95$  — titik di mana **95% kasus depresi** berhasil terdeteksi (minimasi false negative)

0.7033

Precision  $\geq 0.90$  — titik di mana **90% prediksi Tinggi** terbukti benar (konfirmasi risiko)

Rendah

**25.8%**

1123 sample  
(prob < 0.3365)

Sedang


**40.2%**

1749 sample  
(0.3365 – 0.7033)

Tinggi

**34.0%**

1479 sample  
(prob  $\geq 0.7033$ )



# Risk-Based Intervention

## ● Rendah

Probability < 0.3365

Individu menunjukkan sedikit atau tidak ada indikasi depresi berdasarkan profil fitur yang ada

### REKOMENDASI

- Tidak diperlukan intervensi segera
- Pemantauan secara berkala sebagai langkah preventif
- Edukasi kesehatan mental umum
- Memberi panduan menjaga keseimbangan hidup

25.6% populasi · 1115 sampel

## ● Sedang

0.3365 ≤ Probability < 0.703

Individu menunjukkan sejumlah faktor risiko yang perlu dievaluasi lebih lanjut sebelum kesimpulan ditarik

### REKOMENDASI

- Evaluasi lanjutan oleh konselor atau psikolog
- Skrining instrumen klinis (PHQ-9) bersama profesional
- Pemantauan intensif dalam 2–4 minggu

40.4% populasi · 1757 sampel

## ● Tinggi

Probability ≥ 0.7033

Individu memiliki profil risiko yang sangat konsisten dengan pola depresi, sehingga memerlukan tindakan segera


### REKOMENDASI

- Rujukan segera ke profesional kesehatan mental
- Asesmen klinis menyeluruh
- Aktivasi dukungan sosial dan keluarga
- Menghubungi hotline jika dibutuhkan

34.0% populasi · 1479 sampel

# Feature Importances

## KOEFISIEN MODEL LOGISTIC REGRESSION



## FAKTOR RESIKO UTAMA (POSITIF)

- **Academic Pressure (0.777)** — faktor paling dominan, tekanan akademik tinggi berkontribusi besar terhadap risiko depresi
- **Financial Stress (0.518)** — stres finansial adalah faktor kedua terkuat setelah tekanan akademik
- **Work/Study Hours (0.238)** — jam kerja/belajar berlebih turut meningkatkan risiko




## FAKTOR PROTEKTIF (NEGATIF)

- **Age (-0.250)** — usia lebih tua cenderung menurunkan risiko depresi
- **Dietary Habits (-0.239)** — pola makan sehat berperan protektif
- **Study Satisfaction (-0.172)** — kepuasan belajar yang tinggi menurunkan risiko

## ELIMINASI OLEH ELASTIC NET



# MindCheck: Main Page



# MindCheck: Form Application

Form: Data diri

Form: Kehidupan Akademik

Form: Gaya Hidup

MindCheck

Sistem Skrining Kesehatan Mental Mahasiswa

✓

2

3

Data Diri

Akademik

Gaya Hidup

Kehidupan Akademik

Informasi terkait pengalaman akademik Anda

Tekanan Akademik

1

1 / 5

IPK (skala 1-10)

5.00

Kepuasan Belajar

3

3 / 5

Jam Belajar per Hari

6

6 jam per hari

← Kembali

Lanjut →

MindCheck

Sistem Skrining Kesehatan Mental Mahasiswa

1

2

3

Data Diri

Akademik

Gaya Hidup

Data Diri

Mohon isi informasi dasar berikut ini

Jenis Kelamin

Laki-laki

Perempuan

Jenjang Pendidikan

Bachelor / S1

Usia (tahun)

17

Kota

Agra

Lanjut →

MindCheck

Sistem Skrining Kesehatan Mental Mahasiswa

✓

✓

3

Data Diri

Akademik

Gaya Hidup

Gaya Hidup & Kesehatan

Informasi tentang kebiasaan harian dan kondisi Anda

Durasi Tidur Harian

7-8 jam

Kebiasaan Makan

Cukup

Stres Finansial

2

2 / 5

Riwayat Keluarga dengan Gangguan Mental



Tidak

Ya

← Kembali

Lihat Hasil





## SISTEM KLASIFIKASI RISIKO

# Rendah

**P < 0,3365**

Recall  $\geq 95\%$ 

## Sedang

$$0,3365 \leq P < 0,7033$$

## Zona Transisi/Abu-abu

## Sedang

$P \geq 0,7033$

Precision  $\geq 90\%$

## DISTRIBUSI TEST SET

## Risiko Rendah

1123 (25,8%)

## Risiko Sedang

1749 (40,2%)

## Risiko Tinggi

1479 (34,0%)

# Conclusion & Future Work

## PENCAPAIAN PENELITIAN

### 1. Model Terbaik

Logistic Regression dipilih berdasarkan ROC-AUC tertinggi (0.878) dan stabilitas CV terbaik (0.7909)

### 2. Optimasi Berbasis Data

Optuna dengan 100 trials menemukan kombinasi elasticnet optimal, meningkatkan Recall dari 0.8268 → 0.8356

### 3. Output multilevel

Threshold berbasis Precision-Recall Curve (0.3365 & 0.7033) menghasilkan 3 kelas risiko yang actionable secara klinis

### 4. Deployed

Model tersedia sebagai aplikasi Streamlit untuk prediksi risiko depresi secara interaktif

## SARAN PENGEMBANGAN LANJUTAN

### 1. Tambah fitur klinis

Integrasi data seperti riwayat pengobatan atau skor PHQ-9 untuk meningkatkan akurasi prediksi

### 2. Validasi data eksternal

Uji model pada dataset dari institusi atau negara berbeda untuk menguji generalisasi

### 3. Eksplorasi model lanjutan

Lakukan uji coba arsitektur deep learning atau ensemble stacking untuk potensi peningkatan Recall lebih jauh

### 4. Kalibrasi probabilitas

Terapkan Platt Scaling atau Isotonic Regression agar probabilitas output lebih terkalibrasi secara klinis

Penelitian ini menunjukkan bahwa **tekanan akademik dan stres finansial** adalah prediktor dominan depresi pada populasi mahasiswa. Model yang dibangun mampu mendeteksi **83.5% kasus depresi** dan mengklasifikasikannya ke dalam tiga tingkat risiko yang dapat langsung ditindaklanjuti secara klinis.

# Link & Contact

## LIVE APPLICATION

### MindCheck

#### Student Depression Screening System

Aplikasi skrining kesehatan mental mahasiswa berbasis Logistic Regression dengan klasifikasi risiko multilevel — tersedia secara publik via Streamlit Community Cloud.

<https://checkyourmind.streamlit.app>

## DEVELOPER

### Arthur Pendragon

Data Scientist · Machine Learning Enthusiast

- Email: [thedumbestknightever@gmail.com](mailto:thedumbestknightever@gmail.com)
- LinkedIn: [www.linkedin.com/in/arthurpendragon](https://www.linkedin.com/in/arthurpendragon)
- GitHub: <https://github.com/Kingarthuria>
- Colab: <https://drive.google.com/drive/folders/1uXaI8XRHB3SumOKZqviTqXTTDdhwo3xx?usp=sharing>

Seluruh proses pengembangan MindCheck — mulai dari preprocessing, pemilihan model, hingga deployment — tersedia secara terbuka di GitHub. Jika Anda tertarik untuk mengeksplorasi, mereplikasi, atau bahkan mengembangkan lebih lanjut, semua yang Anda butuhkan ada di tautan di atas. Untuk diskusi lebih lanjut, saya terbuka melalui email maupun LinkedIn.